

PrediDepósito

Predicción inteligente de clientes con mayor probabilidad de contratar depósitos

Menos llamadas. Más conversiones.

Maryori | Andres | Iris | Mirae

El Problema de Negocio

45K

Clientes llamados

45,211 clientes contactados sin
priorización

12%

Tasa de conversión

Solo 5,289 clientes suscriben el depósito

88%

Coste innecesario

De las llamadas no generan conversión

¿Podemos predecir quién va a decir Sí antes de llamar?

Nuestra Solución




Modelo predictivo

Machine Learning que analiza el perfil de cada cliente y asigna probabilidad de suscripción



Mayor conversión

El banco solo llama a clientes con mayor probabilidad, aumentando eficiencia



Menor coste

Reducción significativa de llamadas innecesarias y optimización de recursos



Dataset

Dataset: Bank Marketing

UCI Machine Learning Repository - 45,211 clientes reales de un banco portugués con 17 variables: edad, profesión, saldo bancario, historial de campañas

Reto principal

Solo el 12% suscribe → clases muy desbalanceadas

Solución aplicada

Técnica SMOTE aplicada sobre el train set para balancear clases



Cómo Funciona



Analizamos el perfil

Edad, saldo bancario, historial de campañas anteriores



Calculamos probabilidad

El modelo determina la probabilidad de decir Sí



Priorizamos llamadas

El banco contacta primero a clientes de mayor probabilidad

**** El modelo aprende de 45,000 casos históricos reales ****

Variables que Más Importan

1

Saldo bancario

Mayor saldo disponible correlaciona con mayor probabilidad de suscripción

2

Número de contactos

Más de 3 llamadas en campaña anterior reduce significativamente la conversión

3

Éxito en campaña anterior

Si el cliente dijo Sí antes, es muy probable que vuelva a decirlo

4

Edad del cliente

Jóvenes y jubilados muestran mayor tasa de conversión

5

Mes del contacto

Marzo, septiembre, octubre y diciembre son los meses con mejor respuesta

Tecnologías Utilizadas

Lenguaje y Entorno

Python 3.12 · Jupyter Notebooks · VS Code · Git & GitHub

Análisis y Visualización

Pandas · NumPy · Matplotlib · Seaborn

Machine Learning

Scikit-learn · XGBoost · Imbalanced-learn (SMOTE) · Optuna

Gestión del Proyecto

GitHub Projects · Flujo de trabajo por ramas

Resultados del Modelo

Modelo	F1 Score	ROC-AUC
Regresión Logística	0.369	0.767
Random Forest	0.390	0.783
SVM	0.285	0.651
XGBoost ✓	0.391	0.792

53%

Detección optimizada

Con umbral optimizado detectamos al 53% de los clientes que van a decir Sí

Impacto en Negocio

Antes

- 45,211 llamadas realizadas
- 5,289 conversiones (12%)
- 88% de llamadas sin conversión
- Coste elevado de campaña

Después con PrediDepósito

- Llamadas priorizadas por probabilidad
- Mismas conversiones, menos llamadas
- Optimización de recursos
- ROI mejorado significativamente

+246

Clientes extra detectados

Por campaña con predicción inteligente

Perfil del Cliente Ideal

Segmento A: Jubilados

Jubilados con saldo medio-alto, sin hipoteca activa, perfil conservador

Segmento B: Historial positivo

Cientes con éxito en campaña anterior, alta probabilidad de retención

Segmento C: Timing óptimo

Contactados en meses de alta conversión: marzo, septiembre, octubre, diciembre

Conclusión

Capacidad predictiva sólida

Buena capacidad predictiva con un AUC-ROC de 0.79 → Alta probabilidad de contratar un depósito.

Modelo orientado al negocio

Es modelo útil antes del contacto con el cliente.

Aplicación para marketing

Permite reducir el número de llamadas y mejorar la eficiencia de las campañas.

Demo y Código